

ANÁLISE DE SENSIBILIDADE DE PARÂMETROS DO GRASP-VNS NA SOLUÇÃO DA ALOCAÇÃO ÓTIMA DE GERADORES DISTRIBUÍDOS EM REDES ELÉTRICAS

**Bruno de Alencar Rosa Silva, Wilington Guerra Zvietcovich, Francisco Ricardo Abrantes
Couy Baracho, Laerty João dos Santos Damião, Laura Freitas Souza**

Universidade Federal de Ouro Preto

Rua 36, 115, 35931-008, João Monlevade, MG, Brasil

bruno.rosa@aluno.ufop.edu.br, wilington@ufop.edu.br,
f_baracho@ufop.edu.br, laerty.damiao@aluno.ufop.edu.br,
laura.souza1@aluno.ufop.edu.br

RESUMO

Este trabalho apresenta a implementação das meta-heurísticas *Greedy Randomized Adaptive Search Procedure* (GRASP) e *Variable Neighborhood Search* (VNS) para a alocação ótima de Geradores Distribuídos (DGs) em sistemas de distribuição radial, com o objetivo de reduzir as perdas elétricas. Nessa metodologia, o algoritmo GRASP é usado para criar possíveis soluções para o problema, enquanto o VNS é aplicado a um estágio de busca local, no qual é feito um refinamento no espaço de soluções para melhorar a convergência do processo de busca. As simulações foram realizadas em um sistema de 135 barras, onde diversos grupos de parâmetros próprios dos algoritmos GRASP e VNS foram utilizados. Dessa forma, foi possível analisar a sensibilidade das soluções quanto a variações dos parâmetros intrínsecos do algoritmo e, além disso, verificar a eficácia da metodologia em encontrar soluções de boa qualidade em relação ao nível perdas elétricas.

PALAVRAS CHAVE. Geradores Distribuídos; GRASP; Otimização; Sistemas de Distribuição; VNS.

Tópicos: EN&PG – PO na Área de Energia, Petróleo e Gás

ABSTRACT

This paper presents the implementation of the meta-heuristics *Greedy Randomized Adaptive Search Procedure* (GRASP) and *Variable Neighborhood Search* (VNS) for the optimal allocation of Distributed Generators (DGs) in radial distribution systems, aiming at reducing power losses and simultaneously improving voltage levels. In this methodology, the GRASP algorithm is used to build possible solutions to the problem, while the VNS is applied to a local search stage, in which a refinement is made in the solution space to improve the convergence of the search process. The simulations were carried out in a 135-distribution system, where several groups of parameters of the GRASP and VNS algorithms were used. Thus, it was possible to analyze the sensitivity of the solutions for variations in the intrinsic parameters of the algorithm and, in addition, to verify the effectiveness of the methodology in finding good quality solutions in relation to the level of electrical losses.

KEYWORDS. Distributed Generators; Distribution Systems; GRASP; Optimization; VNS.

Paper topic: EN&PG – OR Area of Energy, Oil and Gas

1. Introdução

No Brasil, a maior parte da produção de energia elétrica é tradicionalmente obtida a partir de grandes plantas de geração, distante dos centros de consumo, que fazem parte de um sistema unidirecional da extra-alta e alta tensão para a média e baixa tensão. Entretanto, com o desenvolvimento das tecnologias das fontes renováveis, atrelado às políticas do mercado de energia elétrica, tem-se, aos poucos, viabilizado um novo modelo de geração, conhecido como geração distribuída.

Neste modelo, parte da energia elétrica é gerada e entregue a clientes através de pequenas unidades de geração alocadas próximas aos usuários finais, de modo que os geradores distribuídos (GDs), normalmente pequenas centrais hidroelétricas, parques eólicos ou fotovoltaicos, possam ser aplicados de forma isolada, suprimindo a demanda local de um consumidor específico, ou de forma integrada, fornecendo energia para a rede elétrica [HA et al., 2017]. Desse modo, a aplicação de pequenos geradores, conectados diretamente ao Sistema de Distribuição de Energia Elétrica (SDEE), pode ser suficiente para atender a demanda de consumo de uma determinada região ou grupo de consumidores.

De acordo com [Naik et al., 2013], a operação de GDs pode afetar a operação de um SDEE de maneira benéfica e/ou prejudicial. Nesse contexto, são benefícios: suporte de reativos para melhoria da tensão; mitigação das perdas elétricas; redução de custos relacionados à transmissão; dentre outros. Por outro lado, pode-se destacar os seguintes pontos negativos: redirecionamento da coordenação de proteção; prejuízos à estabilidade do sistema; injeção de harmônicos no SDEE; dentre outros.

Diante de todos esses impactos, sejam eles benéficos ou prejudiciais, vários trabalhos têm abordado a geração distribuída em SDEEs. Nesse sentido, pode-se verificar na literatura que alguns grupos tratam do impacto dos GDs na Qualidade da Energia Elétrica (QEE) [Lakshmi e Ganguly, 2018; Abubakar et al., 2019]; enquanto outros buscam desenvolver modelos matemáticos para representar GDs de diferentes tipos (por exemplo, eólicos, fotovoltaicos e biomassa) [Gupta, 2016; He et al., 2018]. Já outros grupos visam implementar e desenvolver técnicas para definir os melhores locais de instalação de um gerador distribuído [Raut e Mishra, 2020; Sambaiah e Jayabarathi, 2020].

A respeito deste último grupo, no qual se insere este trabalho, muitos avanços são alcançados por meio da aplicação de técnicas de otimização para solucionar problemas de natureza combinatória, com destaque para as heurísticas. Embora os métodos heurísticos sejam intuitivos e simples de implementar, em comparação com métodos de programação numérica, os resultados produzidos por algoritmos heurísticos não são garantidos para serem ótimos [Ng et al., 2000]. Assim, surgem as técnicas meta-heurísticas para aplicações em problemas de maior complexidade.

Por exemplo, em [Lopez et al., 2019], as técnicas *Tabu Search*, *Scatter Search* e *Ant Colony Algorithm* foram aplicadas e avaliadas para a alocação de GDs em SDEEs radiais, com o objetivo de reduzir as perdas ativas. Os autores indicam a aplicabilidade e o desempenho dessas técnicas no problema em questão. Em [Truong et al., 2019], um novo algoritmo, baseado na meta-heurística *Symbiotic Organisms Search* (SOS), foi implementado para determinar a quantidade, a localização e o dimensionamento ótimo de DGs de SDEEs radiais, de modo a reduzir as perdas elétricas ativas. Já em [Ahmed et al., 2020] utilizou-se um algoritmo recentemente proposto, chamado *Salp Swarm Algorithm* (SSA), para otimizar a alocação de GDs eólicos. Para isso, foram considerados parâmetros relacionados a desvio de tensão, perdas e estabilidade. De acordo com os autores, o SSA tem funcionado de modo eficiente em termos de tempo computacional e características de convergência.

Neste contexto, no presente trabalho é desenvolvida uma metodologia híbrida através das

meta-heurísticas GRASP (do inglês: *Greedy Randomized Adaptive Search Procedure*) e VNS (do inglês: *Variable Neighborhood Search*) para alocar GDs em um SDEE, de modo a minimizar os valores de perdas ativas. A metodologia foi aplicada a um sistema de 135 barras, no qual diversos cenários foram simulados para mostrar a sensibilidade da qualidade das soluções encontradas em relação aos parâmetros próprios dessas meta-heurísticas.

2. Formulação do Problema

2.1. Alocação de Geradores Distribuídos

A operação de GDs utilizando diferentes tecnologias impacta os índices de operação das SDEE, mais especificamente as perdas elétricas ativas e os níveis de tensão. Dependendo da sua alocação (barra instalada) e de seu dimensionamento (potência gerada) estes valores mudam. Por exemplo, para o sistema mostrado na Figura 1, tem-se que a alocação de um GD de 400kW na barra 7 é suficiente para elevar a tensão média da rede de 0,9212 para 0,9433 e, ao mesmo tempo, reduzir o valor de perdas de 170kW para 148kW. Isso pode ser útil para adequar a operação de um SDEE de acordo com a legislação vigente (baseado em indicadores de QEE) e reduzir prejuízos relacionados às perdas técnicas.




Figura 1: SDEE radial com GD alocada na barra 7.

A respeito das melhorias proporcionadas ao SDEE, vale ressaltar, no entanto, que elas obedecem a uma relação não-linear, de modo que aumentos significativos da potência gerada por GDs são impliquem, necessariamente, em ganhos à operação. Um exemplo disso é mostrado na Figura 2, na qual verifica-se que o nível de perdas do SDEE, embora possa ser reduzido inicialmente em função de incrementos na capacidade da geração distribuída, apresenta um comportamento ascendente a partir de um determinado valor potência dos GDs.

Diante dos impactos mencionados, da complexidade dos SDEEs, das limitações de potência gerada e das restrições de operação, estabelece-se, portanto, o problema da alocação de GDs. Dessa forma, em virtude do elevado número de possíveis soluções e da necessidade de encontrar a melhor delas, visando reduzir as perdas elétricas e melhorar o perfil de tensão, verifica-se que tal problema se enquadra dentro da programação inteira mista [Wang et al., 2014], sendo resolvido de forma eficiente por métodos de otimização computacional.

2.2. Formulação Matemática da Função Objetivo

Neste trabalho, o problema de alocação foi resolvido visando a redução das perdas ativas. Para isso, tem-se no modelo a seguinte função objetivo:

$$\min F = \sum_{l=1}^{nl} RI_l^2 \quad (1)$$

sujeito a:

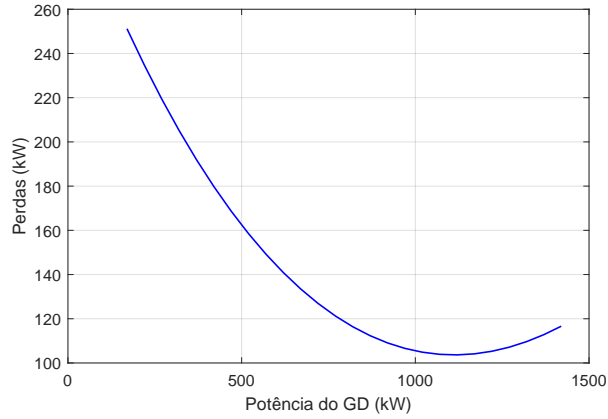


Figura 2: Relação Potência do GD vs. Perdas, considerando alocação na barra 7 do sistema mostrado na Figura 1.

- Capacidade dos alimentadores:

$$I_{min} < I_{in} < I_{max} \quad (2)$$

- Capacidade das subestações:

$$I_{min} < I_{sub} < I_{max} \quad (3)$$

- Capacidade dos GDs:

$$P_{GD,min} < P_{GD} < P_{GD,max} \quad (4)$$

- Equações de fluxo de potência:

$$P_T = \sum_{(k,m) \in \Omega} R_{km} I_{km}^2 \quad (5)$$

$$Q_T = \sum_{(k,m) \in \Omega} X_{km} I_{km}^2 \quad (6)$$

$$\begin{bmatrix} \Delta P \\ \Delta Q \end{bmatrix} = \begin{bmatrix} H & N \\ M & L \end{bmatrix} \begin{bmatrix} \Delta \delta \\ \Delta V/V \end{bmatrix} \quad (7)$$

- Níveis de tensão nas barras:

$$V_{min} < V_k < V_{max} \quad (8)$$

onde:

- nl : total de linhas;
- V_{min} e V_{max} : tensão mínima e máxima de barra, respectivamente;
- V_k : tensão na barra k ;

- $P_{(GD,min)}$ e $P_{(GD,max)}$: potência nominal mínima e máxima de um GD, respectivamente;
- P_{GD} : potência nominal de uma GD;
- P_T e Q_T : potência ativa e reativa total do sistema, respectivamente;
- R_{km} e X_{km} : resistência e reatância da linha entre as barras k e m , respectivamente;
- I_{km} : corrente na linha entre as barras k e m ;
- Ω : conjunto de barras presente na rede elétrica;
- I_{min} e I_{max} : menor e maior corrente suportada pelos alimentadores ou subestação, respectivamente;
- I_{sub} : corrente da subestação;
- I_{in} : corrente do alimentador;
- H, N, M, L : componentes da matriz jacobiana;
- $\Delta\delta, \Delta V, \Delta P$ e ΔQ variação do ângulo das tensões, das tensões e da potência ativa e reativa demandada das barras, respectivamente.

3. Metodologia de Otimização

Para resolver o problema de alocação e dimensionamento de GDs em um SDEE, foram utilizadas duas técnicas meta-heurísticas com a finalidade de aumentar a eficiência na busca das melhores soluções.

A primeira técnica é o GRASP [Feo e Resende, 1989], um algoritmo iterativo que consiste em duas etapas: (i) construção de uma solução; e (ii) busca local. A fase de construção é caracterizada por um algoritmo do tipo guloso, que possui uma componente aleatória e adaptativa. Já a fase de busca local é realizada para encontrar melhores resultados comparados com a solução obtida na primeira fase.

A segunda meta-heurística é o VNS [Mladenović e Hansen, 1997], que consiste em uma técnica baseada em um processo de trocas sistemáticas de parâmetros através de estruturas de vizinhanças dentro do espaço de soluções, com a finalidade de encontrar soluções ótimas. A forma de transitar nas estruturas de vizinhança gera diferentes algoritmos próprios do VNS, sendo aplicado neste trabalho o *Basic VNS* [Mladenović e Hansen, 1997].

3.1. Implementação

3.1.1. Representação de uma Solução

A solução para o problema de Alocação de GDs é representada por uma matriz $m \times 2$, onde m é número de GDs. A Figura 3 ilustra um exemplo para $m = 2$.

	Barra de Alocação	Potência Gerada (kW)
Solução i =	11	300
	25	250

Figura 3: Representação de uma solução.

3.1.2. Avaliação da Função Objetivo

A avaliação da função objetivo é realizada para cada solução determinada no processo de otimização da metodologia GRASP-VNS, visando quantificar a qualidade desta solução. Para isso, executa-se uma análise de fluxo de potência que, neste trabalho, utiliza o método de Newton Raphson [Grainger e Stevenson, 1994] para, em seguida, aplicar a equação (1) e suas restrições.

3.1.3. Critério de Parada

Para o algoritmo GRASP, utilizou-se como critério de parada o número de soluções geradas na etapa de construção de soluções. Já para o VNS, ou seja, para a etapa de busca local, adotou-se como critério o número máximo de visitas em cada estrutura de vizinhança.

3.1.4. Procedimentos do algoritmo GRASP-VNS

A implementação do GRASP, pode ser dividida em três etapas, conforme descrito a seguir [Oliveira, 2011]:

Procedimentos para implementação do GRASP

1ª Etapa: Leitura dos dados do problema e obtenção da solução inicial;

- 1 $f^* \leftarrow \infty; x^* \leftarrow \emptyset;$
- 2 Ler os dados do problema;
- 3 **Para** $Sol = 1, \dots, MaxSol$, **faça**:

2ª Etapa: Realizar a construção de uma solução utilizando componentes aleatórias (fase de construção)

- 4 $\alpha = \text{rand}(0-1).$
- 5 **Se** $\alpha < 0,5$ **faça**:
- 6 Construir uma solução x de forma aleatório.
- 7 **Senão**:
- 8 Construir uma solução x de modo aleatório-guloso.
- 9 **Fim Se**
- 10 **Fim Para**

3ª Etapa: Realizar uma melhoria da solução encontrada na fase construtiva.

- 11 **Para** $k = 1, \dots, MaxIter$, **faça**:
- 12 Encontrar y aplicando busca local a x (fase de busca local);
- 13 **Se** $f(y) < f^*$, **então**:
- 14 $x^* \leftarrow y, f^* \leftarrow f(y);$
- 15 **Fim Se**
- 16 **Fim Para**
- 17 Retorna x^*

FIM GRASP

Na primeira etapa dos procedimentos apresentados é realizada a leitura dos dados do problema e, em seguida, na segunda etapa, determina-se aleatoriamente um parâmetro α que varia entre 0 e 1. Para $\alpha < 0,5$, tem-se um indicador totalmente aleatório. Caso contrário, tem-se um indicador Aleatório-Guloso.

No primeiro caso (algoritmo totalmente aleatório), escolhe-se aleatoriamente a barra na qual será alocado o GD. Em seguida, constroi-se a capacidade de geração do GD e sorteia-se, aleatoriamente, em valor na faixa viável de potência, que é atribuído ao GD. Já no segundo caso (algoritmo aleatório-Guloso), utiliza-se um critério de sensibilidade de tensão (VSI) para determinar a barra de alocação do GD [Subrahmanyam e Radhakrishna, 2009]. O VSI é obtido pela seguinte equação:

$$VSI_j = \sqrt{\frac{\sum_{i=1}^n (1 - V_i)^2}{n}} \quad (9)$$

onde, V_i é a tensão no i -ésimo nó e n é o número de nós. Dessa forma, aloca-se o GD considerando as barras com menor VSI . Já para determinar a capacidade de geração do GD, escolhe-se aleatoriamente um valor na faixa viável de potência.

Na terceira etapa, é aplicada uma busca local com base na solução determinada na etapa anterior, utilizando o algoritmo VNS, cujos procedimentos para implementação são descritos a seguir.

Procedimento para aplicação do VNS na busca local

1ª Etapa: Leitura dos dados do problema e obtenção da solução inicial;

1ª Etapa: Define-se $k_{max}=2$;

2ª Etapa (agitação): é gerada uma solução x' na k -ésima vizinhança de x , trocando-se k GDs de barras ou alterando-se as potências dos k GDs, observando a capacidade de geração da barra na qual o GD será instalado (ver Figura 2).

3ª Etapa (busca local): aplica-se uma busca local em torno de x' , alterando a barra ou a potência de um GD aplicando o “Critério de busca local”. Desta forma, obtém-se a solução x'' e avalia-se o seu custo na função objetivo.

4ª Etapa (mover ou não): caso o valor da função objetivo da solução x'' seja melhor que o valor da solução incumbente x , x'' passa a ser x e volta-se a $k = 1$. Caso contrário, continua-se a busca local (etapa 3) até atingir $Maxvisitas$, que é escolhido de acordo com o tamanho da rede. Atingindo o valor de $Maxvisitas$, faz-se $k = k + 1$;

5ª Etapa: Se $k_{max} \leq 2$: retorna-se ao passo 2; **Senão:** FIM VNS.

Com a finalidade de guiar a busca para melhores soluções, utilizou-se na etapa 2 do algoritmo VNS descrito acima um critério aleatório-determinístico. Nesse critério, para o caso de mudança de barra do GD constrói-se um vetor utilizando o índice de sensibilidade de tensão indicado em (9), ordenando-o de forma ascendente. Em seguida, sorteia-se uma barra no grupo dos 50% dos primeiros elementos do vetor. Já para o caso da mudança de valor de potência, constrói-se a curva de capacidade de potência na barra na qual o GD será realocado ou na barra atual (caso não ocorra realocação de barra) e sorteia-se um valor de potência na faixa de 50% a 100% da capacidade de potência.

Desta forma, a visita de soluções no espaço de busca procura soluções ótimas locais, saindo destas soluções através da troca de estrutura de vizinhança, em busca da solução ótima global.

4. Resultados

Neste item, são apresentados os resultados obtidos aplicando a metodologia proposta. A implementação computacional foi realizada em ambiente Matlab e aplicada a uma rede de 135 barras [Guimarães et al., 2005] ilustrada na Figura 4. O número de GDs a serem alocados, bem como a especificação dos critérios de parada do algoritmo são mostrados na Tabela 1.

Para a simulação, diversos parâmetros do algoritmo GRASP-VNS foram considerados para uma análise de sensibilidade. O total de combinações dos parâmetros para cada disponibilidade do número de GDs é igual 72, sendo, no entanto, simulado neste trabalho 36 combinações de forma aleatória devido à limitação do tempo de simulação. Uma combinação de parâmetros é chamada de “cenário” na análise dos resultados. A Tabela 2 ilustra os resultados obtidos.

Os 36 cenários foram agrupados em função do valor das perdas elétricas mínimas encontradas (colunas 3 e 4), sendo construídos 9 e 15 grupos para 2 e 3 GDs, respectivamente. Por exemplo, o Grupo 1 (para 2 GDs) representa os cenários 17, 34, 31, 23, 36 e 8, nos quais foram encontrados perdas elétricas mínimas na faixa de 173,503kW a 173,822kW.

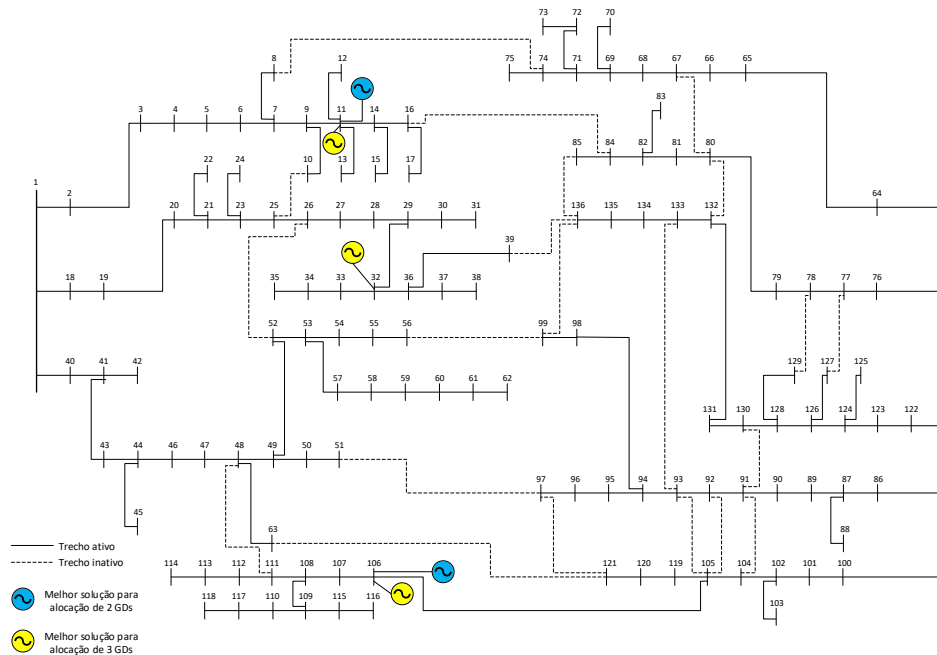


Figura 4: SDEE de 135 barras.

Tabela 1: Parâmetros da metodologia.

Parâmetros	Valores considerados				Aplicação (item 3.1.4)
Nº de GDs a serem alocados	2; 3				--
Nº de soluções GRASP	10	20	40		Etapa 1 GRASP (MaxSol)
Faixa máxima (critério aleatório-guloso GRASP)	50	70	100		Etapa 2 GRASP (Critério Aleatório-Guloso)
Faixa máxima (Critério de busca local) VNS	50	70			Etapa 3 VNS (Busca local)
Nº máximo de visitas na Nk (VNS)	20xK	40xK	80xK	100xK	Etapa 1 VNS (k=1,2)

O desvio padrão (colunas 5 e 6) refere-se à dispersão dos valores médios de perdas mínimas encontradas nos cenários de cada grupo avaliado. Por exemplo, considerando o Grupo 1 (para 2 GDs), cada um dos 6 cenários avaliados apresenta um determinado conjunto de soluções que totalizam 6 valores de desvio padrão, sendo 5,7kW o valor mínimo de desvio e 8,5kW o valor máximo.

Um parâmetro que avalia o esforço computacional para encontrar os resultados é a quantidade de fluxos de carga para avaliar a função objetivo. Os resultados deste parâmetro são indicados nas colunas 7 e 8 da Tabela 2. Por exemplo, no Grupo 1 (para 2 GDs) cada um dos 6 cenários possui uma melhor solução associada a uma quantidade de fluxos de carga. Assim obtém-se 6 valores de quantidade de fluxos de carga, sendo que os valores mínimos e máximos de execuções dos cálculos de fluxo de carga são 244 e 936, respectivamente.

Cada cenário é caracterizado por valores próprios indicados na Tabela 1 e são ilustrados na Tabela 3. A modo de exemplificação, considerando o Grupo 1, cada um dos 6 cenários avaliados apresenta uma melhor solução com uma determinada configuração de parâmetros (ver Tabela 1)

Tabela 2: Resultados para o SDEE de 135 barras.

N° do Grupo de cenários	Cenários de cada grupo	Perda Elétrica [AP] (kW)				Fluxos de carga	
		Valor Mínimo		Desvio Padrão		Valor Mínimo	
		Min.	Max.	Min.	Max.	Min.	Max.
Para Dois GDs							
1	17 34 31 23 36 8	173,503	173,822	5,7	8,5	244	936
2	7 6 32 28 33 24 20 15 18 35 1 16	174,065	174,984	4,9	18,7	100	720
3	4 30 13 2 26 3 19	175,062	175,610	4,3	10,7	112	492
4	29 27	176,118	176,597	5,2	13,0	154	574
5	25	177,903	177,903	11,9	11,9	128	128
6	11 12 14 10 9	178,029	178,629	4,7	16,1	92	602
7	22	180,804	180,804	7,5	7,5	220	220
8	21	181,049	181,049	13,4	13,4	104	104
9	5	182,381	182,381	14,0	14,0	122	122
Para Três GDs							
1	27	142,186	142,186	10,4	10,4	668	668
2	30 15	144,744	144,919	8,8	11,1	170	616
3	20	145,685	145,685	7,2	7,2	938	938
4	28 33	146,020	146,220	11,1	15,2	116	420
5	4 16 36	147,134	147,611	8,0	10,3	362	786
6	29 21 19 34 9 7 25	148,269	148,738	7,6	18,2	118	696
7	26 28 32 14 35 23 5 31 12	149,070	149,937	6,9	13,2	208	722
8	11 8	150,465	150,468	5,9	9,5	624	850
9	3 13	151,126	151,275	11,5	13,5	196	1004
10	24	152,183	152,183	9,0	9,0	344	344
11	17	153,264	153,264	16,4	16,4	90	90
12	2	154,937	154,937	11,0	11,0	314	314
13	22 6	155,174	155,212	7,1	9,5	274	460
14	1	156,038	156,038	14,1	14,1	150	150
15	10	159,035	159,035	10,6	10,6	332	332

que são especificados nas colunas 2, 3, 4 e 5 na forma “parâmetro” (quantidade de soluções). Desse modo, pode-se verificar na coluna 2 do Grupo 1, por exemplo, que 1 solução foi obtida com o número de soluções do GRASP igual a 10, enquanto 2 foram encontradas para o número de soluções do GRASP igual a 20 e as 3 restantes foram encontradas para o número de soluções do GRASP igual a 40.

Análise de Resultados: Observa-se na Tabela 2 que soluções de boa qualidade, em termos das perdas, foram encontradas em vários cenários tanto para 2 quanto para 3 GDs. Por outro lado, quanto ao desvio padrão, pode-se afirmar que, para 2 GDs, a convergência para melhores soluções foi melhor quando comparada com aquelas obtidas para 3 GDs. Por sua vez, a respeito da quantidade demandada de cálculos de fluxo de carga, verifica-se que os valores são divergentes entre os diferentes grupos avaliados.

Na Tabela 3 observa-se que um maior número de soluções no GRASP (coluna 2) contribui para encontrar melhores soluções, confirmando a diversidade no espaço de soluções como uma característica principal no processo de otimização. Já a coluna 3 (forma de construção da solução GRASP) indica que restringir a construção de soluções utilizando o critério heurístico (eq. (9)) contribui para a obtenção de melhores soluções. De forma similar, verifica-se que restringir a busca de soluções no VNS (coluna 4), visando guiar o algoritmo para soluções ótimas locais, contribui para visitar melhores soluções, assim como aumentar o número de visitas em cada estrutura de vizinhança (coluna 5).

Diante das simulações, tem-se, na Tabela 4, as três melhores soluções encontradas pela metodologia, onde além dos valores de perdas, podem ser analisadas as barras de alocação, bem como a potência dos GDs e o nível de tensão médio estabelecido no sistema elétrico. A respeito desse último aspecto, especificamente, é mostrado na Figura 5 a melhoria proporcionada pela alocação de GDs no SDEE de 135 barras, considerando a melhor solução (Melhor 1) para a alocação de 3 GDs.

Tabela 3: Descrição dos resultados para cada grupo de cenários avaliado.

Nº do Grupo de cenários	Nº de Soluções GRASP	Faixa máxima (critério aleatório-grugoso GRASP)	Faixa máxima (Critério de busca local) VNS	Nº máximo de visitas na Nk (VNS)
Para Dois GDs				
1	10(1)20(2)40(3)	50(0)70(3)100(3)	50(3)70(3)	20(1)40(1)80(2)100(2)
2	10(3)20(5)40(4)	50(4)70(5)100(3)	50(9)70(3)	20(2)40(2)80(3)100(5)
3	10(3)20(2)40(2)	50(5)70(2)100(0)	50(7)70(0)	20(1)40(3)80(2)100(1)
4	10(0)20(0)40(2)	50(1)70(1)100(0)	50(2)70(0)	20(1)40(0)80(1)100(0)
5	10(0)20(0)40(1)	50(1)70(0)100(0)	50(1)70(0)	20(1)40(0)80(0)100(0)
6	10(4)20(1)40(0)	50(1)70(0)100(4)	50(1)70(4)	20(1)40(2)80(1)100(1)
7	10(0)20(1)40(0)	50(0)70(0)100(1)	50(0)70(1)	20(0)40(1)80(0)100(0)
8	10(0)20(1)40(0)	50(0)70(0)100(1)	50(0)70(1)	20(1)40(0)80(0)100(0)
9	10(1)20(0)40(0)	50(0)70(1)100(0)	50(1)70(0)	20(1)40(0)80(0)100(0)
Para Três GDs				
1	10(0)20(0)40(1)	50(1)70(0)100(0)	50(1)70(0)	20(0)40(0)80(1)100(0)
2	10(0)20(1)40(1)	50(1)70(1)100(0)	50(2)70(0)	20(0)40(1)80(1)100(0)
3	10(0)20(1)40(0)	50(0)70(0)100(0)	50(1)70(0)	20(0)40(0)80(0)100(1)
4	10(0)20(1)40(1)	50(0)70(1)100(1)	50(1)70(1)	20(1)40(1)80(0)100(0)
5	10(1)20(1)40(1)	50(2)70(0)100(1)	50(2)70(1)	20(0)40(0)80(0)100(3)
6	10(2)20(2)40(3)	50(1)70(3)100(3)	50(4)70(3)	20(4)40(1)80(2)100(0)
7	10(2)20(2)40(5)	50(3)70(3)100(3)	50(6)70(3)	20(1)40(2)80(3)100(3)
8	10(2)20(0)40(0)	50(0)70(1)100(1)	50(1)70(1)	20(0)40(0)80(1)100(1)
9	10(1)20(1)40(0)	50(2)70(0)100(0)	50(2)70(0)	20(1)40(0)80(1)100(0)
10	10(0)20(1)40(0)	50(0)70(0)100(1)	50(0)70(1)	20(0)40(0)80(0)100(1)
11	10(0)20(1)40(0)	50(0)70(1)100(0)	50(1)70(0)	20(1)40(0)80(0)100(0)
12	10(1)20(0)40(0)	50(1)70(0)100(0)	50(1)70(0)	20(0)40(1)80(0)100(0)
13	10(1)20(1)40(0)	50(0)70(1)100(1)	50(1)70(1)	20(0)40(2)80(0)100(0)
14	10(1)20(0)40(0)	50(1)70(0)100(0)	50(1)70(0)	20(1)40(0)80(0)100(0)
15	10(1)20(0)40(0)	50(0)70(70)100(1)	50(0)70(1)	20(0)40(1)80(0)100(0)

Tabela 4: Melhores soluções encontradas.

Respostas	Barra alocadas	Potência ativa dos GDs (kW)	Potência reativa dos GDs (kVAR)	Perdas elétricas (kW)	V /min p.u.	Nº de fluxos de potência
Sem GDs	--	--	--	320,278	0,931	--
Com 2 GDs						
Solução aleatória	32; 118	2094; 1515	975,4; 771,7	227,897	0,971	--
Melhor 1	11; 106	2362; 2942	878,6; 509,6	173,585	0,971	342
Melhor 2	11; 106	2053; 2636	1024,9; 642,1	174,417	0,971	417
Melhor 3	11; 106	2009; 2681	884,3; 622,4	175,247	0,971	292
Com 3 GDs						
Solução aleatória	4; 62; 103	2423; 482; 280	1103,8; 1061,3; 832,1	292,510	0,934	--
Melhor 1	11; 32; 106	2390; 2019; 2852	865,5; 1011,5; 548,2	142,186	0,971	668
Melhor 2	11; 49; 106	1937; 2186; 2859	1080,3; 902; 545,2	144,788	0,971	820
Melhor 3	11; 27; 107	2197; 2062; 2719	956,5; 1063,1; 1003,9	145,370	0,971	937

Outro parâmetro avaliado para esta rede é a curva de redução de perdas elétricas no processo de otimização, mostrada na Figura 6, na qual se observa que a solução inicial (iteração 0) é gerada pela etapa 1 do GRASP. Destaca-se nessa curva que a redução de perdas no decorrer das




Figura 5: Melhoria no perfil de tensão após alocação dos GDs.

iterações é obtida devido ao processo de busca local garantido pela técnica VNS.




Figura 6: Convergência do algoritmo GRASP-VNS.

5. Conclusões

Neste trabalho se apresenta a aplicação das meta-heurísticas GRASP-VNS para solucionar o problema de alocação ótima de GDs e seu dimensionamento, visando reduzir as perdas elétricas e melhorar os níveis de tensão em um SDEE.

A aplicação destas técnicas representa uma ferramenta adicional para solucionar este problema, acrescentando na literatura uma nova aplicação.

Foram considerados diferentes valores dos parâmetros próprios das técnicas metaheurísticas com a finalidade de encontrar configurações destes, que levem às melhores soluções.

A utilização do VNS na etapa de busca local do GRASP foi crucial para encontrar melhores resultados e sair de soluções ótimas locais através de estruturas de vizinhança.

Dos resultados, afirma-se que a inserção de poucos GDs no SDEE traz ganhos, com redução de custos de perdas elétricas, assim como de QEE, quanto ao melhoramento de níveis de tensão.

Como trabalhos futuros, pretendesse fazer o estudo utilizando curvas de consumo associadas a medidores, assim como aplicar em redes de maior porte.

Referências

- Abubakar, A. S., Olaniyan, A. A., Ibrahim, A., e Sulaiman, S. H. (2019). An improved analytical method for optimal sizing and placement of power electronic based distributed generation considering harmonic limits. In *2019 IEEE PES/IAS PowerAfrica*, p. 122–127. IEEE.
- Ahmed, A., Nadeem, M. F., Sajjad, I. A., Bo, R., e Khan, I. A. (2020). Optimal allocation of wind dg with time varying voltage dependent loads using bio-inspired: Salp swarm algorithm. In *2020 3rd iCoMET*, p. 1–7. IEEE.

- Feo, T. A. e Resende, M. G. (1989). A probabilistic heuristic for a computationally difficult set covering problem. *Operations research letters*, 8(2):67–71.
- Grainger, J. e Stevenson, W. (1994). Power system analysis.
- Guimarães, M. A. d. N. et al. (2005). Reconfiguração de sistemas de distribuição de energia elétrica utilizando algoritmos de busca tabu.
- Gupta, N. (2016). Probabilistic load flow with detailed wind generator models considering correlated wind generation and correlated loads. *Renewable Energy*, 94:96–105.
- HA, M. P., Huy, P. D., e Ramachandaramurthy, V. K. (2017). A review of the optimal allocation of distributed generation: Objectives, constraints, methods, and algorithms. *Renewable and Sustainable Energy Reviews*, 75:293–312.
- He, Y., Pang, Y., Li, X., e Zhang, M. (2018). Dynamic subsidy model of photovoltaic distributed generation in china. *Renewable energy*, 118:555–564.
- Lakshmi, S. e Ganguly, S. (2018). Modelling and allocation of open-upqc-integrated pv generation system to improve the energy efficiency and power quality of radial distribution networks. *IET Renewable Power Generation*, 12(5):605–613.
- Lopez, L., Doria-Garcia, J., Pimienta, C., e Arango-Manrique, A. (2019). Distributed generation allocation and sizing: A comparison of metaheuristics techniques. In *2019 IEEEIC/I&CPS*. IEEE.
- Mladenović, N. e Hansen, P. (1997). Variable neighborhood search. *Computers & operations research*, 24(11):1097–1100.
- Naik, S. G., Khatod, D., e Sharma, M. (2013). Optimal allocation of combined dg and capacitor for real power loss minimization in distribution networks. *IJEPS*, 53:967–973.
- Ng, H., Salama, M., e Chikhani, A. (2000). Classification of capacitor allocation techniques. *IEEE Transactions on power delivery*, 15(1):387–392.
- Oliveira, M. B. C. d. (2011). Reconfiguração de alimentadores em sistemas de distribuição usando a metaheurística grasp.
- Raut, U. e Mishra, S. (2020). An improved sine-cosine algorithm for simultaneous network reconfiguration and dg allocation in power distribution systems. *Applied Soft Computing*, p. 106293.
- Sambaiah, K. S. e Jayabarathi, T. (2020). A survey on load/power flow methods and dg allocation using grasshopper optimization algorithm in distribution networks. In *Soft Computing for Problem Solving*, p. 621–630. Springer.
- Subrahmanyam, J. e Radhakrishna, C. (2009). Distributed generator placement and sizing in unbalanced radial distribution system. *International Journal of Electrical Power and Energy Systems Engineering*, 2(4):232–239.
- Truong, K. H., Nallagownden, P., Elamvazuthi, I., e Vo, D. N. (2019). An improved meta-heuristic method to maximize the penetration of distributed generation in radial distribution networks. *Neural Computing and Applications*, p. 1–23.
- Wang, Z., Chen, B., Wang, J., Kim, J., e Begovic, M. M. (2014). Robust optimization based optimal dg placement in microgrids. *IEEE Transactions on Smart Grid*, 5(5):2173–2182.